

# Regresión Bayesiana - Caso Particular Probabilidad Gaussiana

- En Máxima Verosimilitud:

$$t_n = \phi(x_n)w + \eta; \quad \eta \sim N(\eta | 0, \sigma^2); \quad t_n \in \mathbb{R}^+, \phi(x_n), w \in \mathbb{R}^Q, x_n \in \mathbb{R}^P$$
$$\eta = t_n - \phi(x_n)w \sim N(t_n | \phi(x_n)w, \sigma^2)$$

- Asumiendo datos i.i.d.:  $p(t | \phi, w, \sigma^2) = \prod_{n=1}^N N(t_n | \phi(x_n)w, \sigma^2)$

$$\phi \in \mathbb{R}^{N \times Q}; t \in \mathbb{R}^N$$

- La solución puntual por máx verosimilitud:

$$w_{ML} = (\phi^T \phi)^{-1} \phi^T t; \quad B_{ML} = \frac{1}{\sigma_{ML}^2}$$

$$\frac{1}{B_{ML}} = \frac{1}{N} \sum_{n=1}^N (t_n - \phi(x_n)w_{ML})^2$$

- Podemos estimar la distribución predictiva sobre  $t$ :

$$p(t | \phi(x), w_{ML}, \sigma_{ML}^2) = N(t | \phi(x)w_{ML}, \sigma_{ML}^2)$$

- Si incluimos un tratamiento "más" Bayesiano, podemos incluir un prior (suposición de incertidumbre sobre los parámetros):

$$p(w|\sigma_w^2) = N(w|0, \sigma_w^2 I)$$

$$p(t, \phi, w, \sigma^2, \sigma_w^2) = p(t|\phi w, \sigma^2) p(w|\sigma_w^2)$$

$$p(w|t, \phi, \sigma^2, \sigma_w^2) = \frac{p(t|\phi w, \sigma^2) p(w|\sigma_w^2)}{p(t)}$$

$$p(w|t, \phi, \sigma^2, \sigma_w^2) \propto p(t|\phi w, \sigma^2) p(w|\sigma_w^2)$$

### MÁX A - POSTERIORI (MAP)

EJERCICIO: Demuestre que máx el log-MAP es equivalente a minimizar:

$$\frac{1}{2\sigma^2} \sum_{n=1}^N (t_n - \phi(x_n)w)^2 + \frac{1}{2\sigma_w^2} \|w\|_2^2$$

## Distribución predictiva:

- Dado una entrada nueva  $\mathbf{x}$ , la incertidumbre sobre la estimación de la predicción  $t$   $p(t|\phi(\mathbf{x}), \phi, w)$ , se puede modelar como:

$$p(t|\phi(\mathbf{x}), w) = \int p(t|\phi(\mathbf{x})w) p(w|t, \phi w) dw$$

**EJERCICIO:** Demuestre que para verosimilitud y prior Gaussianas, la predictiva en un regresor Bayesiano se obtiene como:

$$p(t|\phi(\mathbf{x})w) = N(t|\mu(\mathbf{x}), s^2(\mathbf{x}))$$

$$\mu(\mathbf{x}) = \frac{1}{\sigma_w^2} \phi(\mathbf{x})^T \mathcal{S}^{-1} \sum_{n=1}^N \phi(\mathbf{x}_n) t_n$$

$$s^2(\mathbf{x}) = \sigma_w^2 + \phi(\mathbf{x})^T \mathcal{S}^{-1} \phi(\mathbf{x})$$

$$\mathcal{S} = \left[ \frac{1}{\sigma_w^2} \mathbf{I} + \frac{1}{\sigma_w^2} \sum_{n=1}^N \phi(\mathbf{x}_n) \phi(\mathbf{x}_n)^T \right]^{-1}$$

¿Cuál es la relación entre mín cuadrados regularizado y la predictiva?

# Distribución Gaussiana.

- Gaussiana univariada:  $N(x|\mu, \sigma^2) = \frac{1}{\sqrt{2\pi\sigma^2}} \exp\left(-\frac{1}{2} \frac{(x-\mu)^2}{\sigma^2}\right)$   
 $x, \mu \in \mathbb{R}; \sigma^2 \in \mathbb{R}^+$




- Gaussiana multivariada:

$\mathbf{x}, \mu \in \mathbb{R}^p; \Sigma \in \mathbb{R}^{p \times p}$

$$N(\mathbf{x}|\mu, \Sigma) = \frac{1}{(2\pi)^{p/2} |\Sigma|^{1/2}} \exp\left(-\frac{1}{2} (\mathbf{x}-\mu)^T \Sigma^{-1} (\mathbf{x}-\mu)\right)$$

EJERCICIO: - Demuestre, mediante simulación, que para  $X_n \sim p(x_n) = U(x_n | a, b)$   
 $\lim_{N \rightarrow \infty} \frac{1}{N} \sum_{n=1}^N X_n \sim N\left(\frac{1}{N} \sum_{n=1}^N x_n | \mu_x, \sigma_x^2\right)$ . Teorema del límite central

- Pruebe  $N \in \{1, 2, 10\}$



- La forma cuadrática en la Gaussiana Multivariada:


$$\Delta^2 = (\mathbf{x} - \boldsymbol{\mu})^\top \boldsymbol{\Sigma}^{-1} (\mathbf{x} - \boldsymbol{\mu})$$

$$\boldsymbol{\Sigma} = \sum_{j=1}^p \lambda_j \mathbf{u}_j \mathbf{u}_j^\top, \quad \boldsymbol{\Sigma} \mathbf{u}_j = \lambda_j \mathbf{u}_j \rightarrow \text{eigen decomposition.}$$

$$\boldsymbol{\Sigma}^{-1} = (\mathbf{U} \boldsymbol{\Delta} \mathbf{U}^\top)^{-1} = \mathbf{U} \boldsymbol{\Delta}' \mathbf{U}^\top = \sum_{j=1}^p \frac{1}{\lambda_j} \mathbf{u}_j \mathbf{u}_j^\top$$

$$\Delta^2 = (\mathbf{x} - \boldsymbol{\mu})^\top \sum_{j=1}^p \frac{1}{\lambda_j} \mathbf{u}_j \mathbf{u}_j^\top (\mathbf{x} - \boldsymbol{\mu}) = \sum_{j=1}^p \frac{1}{\lambda_j} \underbrace{(\mathbf{x} - \boldsymbol{\mu})^\top \mathbf{u}_j}_{y_j} \underbrace{\mathbf{u}_j^\top (\mathbf{x} - \boldsymbol{\mu})}_{y_j}$$

$$\Delta^2 = \sum_{j=1}^p \frac{y_j^2}{\lambda_j}$$



# Distribuciones Gaussianas condicionales

- Supongamos  $\mathbf{x} = \begin{bmatrix} x_a \\ x_b \end{bmatrix}$ ;  $\boldsymbol{\mu} = \begin{bmatrix} \mu_a \\ \mu_b \end{bmatrix}$ ;  $\boldsymbol{\Sigma} = \begin{bmatrix} \Sigma_{aa} & \Sigma_{ab} \\ \Sigma_{ba} & \Sigma_{bb} \end{bmatrix}$

$$\mathcal{N}(\mathbf{x} | \boldsymbol{\mu}, \boldsymbol{\Sigma})$$

$$\text{con } \Sigma_{ab} = \Sigma_{ba}^T.$$

Ejercicio: Si  $\mathbf{x} \in \mathbb{R}^P$ ,  $x_a \in \mathbb{R}^P$   
 $x_b \in ?$   $\boldsymbol{\mu} \in ?$   $\boldsymbol{\mu}_a \in \mathbb{R}^?$

$\boldsymbol{\mu}_b \in \mathbb{R}^?$   $\Sigma_{aa} \in \mathbb{R}^?$   
 $\Sigma_{ab} \in \mathbb{R}^?$   $\Sigma_{bb} \in \mathbb{R}^?$   
 $\Sigma_{ba} \in \mathbb{R}^?$

- A partir de la matriz de precisión:

$$\boldsymbol{\Lambda} = \boldsymbol{\Sigma}^{-1}; \quad \boldsymbol{\Lambda} = \begin{bmatrix} \Lambda_{aa} & \Lambda_{ab} \\ \Lambda_{ba} & \Lambda_{bb} \end{bmatrix}$$

- Para  $p(x_a | x_b)$ ; con  $p(\mathbf{x}) = p(x_a, x_b)$ :

$$-\frac{1}{2} (\mathbf{x} - \boldsymbol{\mu})^T \boldsymbol{\Sigma}^{-1} (\mathbf{x} - \boldsymbol{\mu}) = -\frac{1}{2} \left( [x_a, x_b] - [\mu_a, \mu_b] \right)^T \underbrace{\begin{bmatrix} \Sigma_{aa} & \Sigma_{ab} \\ \Sigma_{ba} & \Sigma_{bb} \end{bmatrix}^{-1}}_{\boldsymbol{\Lambda}} \left( [x_a, x_b] - [\mu_a, \mu_b] \right)$$

$$-\frac{1}{2} (\mathbf{x}^T - \boldsymbol{\mu}^T) \boldsymbol{\Sigma}^{-1} (\mathbf{x} - \boldsymbol{\mu}) = -\frac{1}{2} \left[ [x_a - \mu_a, x_b - \mu_b]^T \begin{bmatrix} \Lambda_{aa} & \Lambda_{ab} \\ \Lambda_{ba} & \Lambda_{bb} \end{bmatrix} [x_a - \mu_a, x_b - \mu_b] \right]$$

$$-\frac{1}{2} \left[ \mathbf{x}^T \Sigma^{-1} \mathbf{x} - \mathbf{x}^T \Sigma^{-1} \mathbf{u} - \mathbf{u}^T \Sigma^{-1} \mathbf{x} + \mathbf{u}^T \Sigma^{-1} \mathbf{u} \right] = -\frac{1}{2} \mathbf{x}^T \Sigma^{-1} \mathbf{x} + \frac{1}{2} \mathbf{x}^T \Sigma^{-1} \mathbf{u} - \frac{1}{2} \mathbf{u}^T \Sigma^{-1} \mathbf{u}$$

$\mathbf{x}^T \Sigma^{-1} \mathbf{u} = \mathbf{u}^T \Sigma^{-1} \mathbf{x} = \langle \mathbf{u}, \mathbf{x} \rangle_{\Sigma^{-1}}$ , con  $\Sigma > 0 \rightarrow$  definida positiva

Por lo tanto:

$$-\frac{1}{2} \mathbf{x}^T \Sigma^{-1} \mathbf{x} + \mathbf{x}^T \Sigma^{-1} \mathbf{u} - \underbrace{\frac{1}{2} \mathbf{u}^T \Sigma^{-1} \mathbf{u}}_{\text{cte en } \mathbf{x}} = -\frac{1}{2} \left[ [x_a - u_a, x_b - u_b]^T \begin{bmatrix} \Lambda_{aa} & \Lambda_{ab} \\ \Lambda_{ba} & \Lambda_{bb} \end{bmatrix} [x_a - u_a, x_b - u_b] \right]$$

$$-\frac{1}{2} \underbrace{\mathbf{x}^T \Sigma^{-1} \mathbf{x}}_{\substack{\downarrow \\ \text{cuadráticos} \\ \text{en } \mathbf{x}}} + \underbrace{\mathbf{x}^T \Sigma^{-1} \mathbf{u}}_{\substack{\downarrow \\ \text{lineal} \\ \text{en } \mathbf{x}}} + \text{cte} = -\frac{1}{2} \left[ (x_a - u_a)^T \Lambda_{aa} + (x_b - u_b)^T \Lambda_{bb}, (x_a - u_a)^T \Lambda_{ab} + (x_b - u_b)^T \Lambda_{ba} \right] \dots$$

$$\dots [x_a - u_a, x_b - u_b]$$

$$= -\frac{1}{2} \left[ (x_a - u_a)^T \Lambda_{aa} (x_a - u_a) + (x_b - u_b)^T \Lambda_{bb} (x_b - u_b) + (x_a - u_a)^T \Lambda_{ab} (x_b - u_b) + (x_b - u_b)^T \Lambda_{ba} (x_a - u_a) \right]$$

$p(x_a | x_b) = ?$  ENCONTRAREMOS  $u_a$  y  $\Sigma_{ab}$  COMPLETANDO

CUADRADOS

$$p(x) = p([x_a, x_b]) ; \quad p(x_a | x_b) = \mathcal{N}(x_a | \mu_{a|b}, \Sigma_{a|b})$$

Reescribiendo:

$$\begin{aligned}
 -\frac{1}{2} (x - \mu)^T \bar{\Sigma}^{-1} (x - \mu) &= -\frac{1}{2} \cancel{x_a^T \Delta_{aa} x_a} + \cancel{x_a^T \Delta_{aa} \mu_a} - \frac{1}{2} \mu_a^T \Delta_{aa} \mu_a \\
 &\quad - \cancel{\frac{1}{2} x_b^T \Delta_{bb} x_b} + \frac{1}{2} x_b^T \Delta_{bb} \mu_a + \cancel{\frac{1}{2} \mu_b^T \Delta_{bb} x_a} - \frac{1}{2} \mu_b^T \Delta_{bb} \mu_a \\
 &\quad - \cancel{\frac{1}{2} x_a^T \Delta_{ab} x_b} + \cancel{\frac{1}{2} x_a^T \Delta_{ab} \mu_b} + \frac{1}{2} \mu_a^T \Delta_{ab} x_b - \frac{1}{2} \mu_a^T \Delta_{ab} \mu_b \\
 &\quad - \frac{1}{2} x_b^T \Delta_{bb} x_b + x_b^T \Delta_{bb} \mu_b - \frac{1}{2} \mu_b^T \Delta_{bb} \mu_b
 \end{aligned}$$

- Para determinar  $p(x_a | x_b)$  encontramos la dependencia de  $x_a$  con  $x_b$  asumiendo  $x_b$  constante.

- Buscamos el término cuadrático en  $x_a$ :  $-\frac{1}{2} x_a^T \Delta_{aa} x_a$

- Del término cuadrático  $\Sigma_{ab} = \Delta_{aa}$

- Ahora buscamos los términos lineales en  $x_a$ :

$$\underbrace{x_a^T \Delta_{aa} \mu_a}_{-\frac{1}{2} x_a^T \Delta_{aa} x_a} - \underbrace{\frac{1}{2} x_b^T \Delta_{bb} x_a}_{+ \frac{1}{2} \mu_b^T \Delta_{bb} x_a} + \underbrace{\frac{1}{2} \mu_b^T \Delta_{bb} \mu_a}_{- \frac{1}{2} x_a^T \Delta_{ab} \mu_b} + \underbrace{\frac{1}{2} x_a^T \Delta_{ab} \mu_b}_{+ \frac{1}{2} x_a^T \Delta_{ab} \mu_b}$$

- Tenemos que:

$$\mathbf{x}_a^T \Delta_{aa} u_a - \mathbf{x}_a^T \Delta_{ab} \mathbf{x}_b + \mathbf{x}_a^T \Delta_{ab} u_b = \mathbf{x}_a^T (\Delta_{aa} u_a - \Delta_{ab} \mathbf{x}_b + \Delta_{ab} u_b) \\ = \mathbf{x}_a^T (\Delta_{aa} u_a + \Delta_{ab} (u_b - \mathbf{x}_b))$$

- Buscamos despejar el término lineal en  $\mathbf{x}$  desde  $\mathbf{x}^T \bar{\Sigma}^{-1} u$ :

$$\mathbf{x}_a^T \bar{\Sigma}_{ab}^{-1} u_{ab} = \mathbf{x}_a^T (\Delta_{aa} u_a - \Delta_{ab} (u_b - \mathbf{x}_b))$$

- Sabemos que  $\bar{\Sigma}_{ab}^{-1} = \Delta_{aa}$  y:

$$\bar{\Sigma}_{ab}^{-1} \bar{\Sigma}_{ab} u_{ab} = \sum_{ab} (\Delta_{aa} u_a - \Delta_{ab} (u_b - \mathbf{x}_b))$$

$$u_{ab} = \bar{\Sigma}_{ab}^{-1} \bar{\Sigma}_{ab} u_a - \bar{\Sigma}_{ab}^{-1} \bar{\Sigma}_{ab}^{ab} (u_b - \mathbf{x}_b)$$

$$u_{ab} = u_a - \Delta_{aa}^{-1} \Delta_{ab} (u_b - \mathbf{x}_b)$$

NOTA: Dados que:  $\bar{\Sigma}^{-1} = \begin{bmatrix} \Sigma_{aa} & \Sigma_{ab} \\ \Sigma_{ba} & \Sigma_{bb} \end{bmatrix}^{-1} = \Delta^{-1} \begin{bmatrix} \Lambda_{aa} & \Lambda_{ab} \\ \Lambda_{ba} & \Lambda_{bb} \end{bmatrix}$

Usando la identidad de la matriz inversa por partes:

$$\begin{bmatrix} A & B \\ C & D \end{bmatrix}^{-1} = \begin{bmatrix} M & -MBD^{-1} \\ -D^{-1}CM & D^{-1} + D^{-1}CMD^{-1} \end{bmatrix}$$

Siendo  $M = (A - BD^{-1}C)^{-1}$ ; con  $D^{-1}$  el complemento de Schur.

EJERCICIO: Demuestre que:

Nota:  $M\bar{M}^{-1} = I = \bar{M}^{-1}M$

$$\Lambda_{ab} = \Lambda_a + \Sigma_{ab}\bar{\Sigma}_{bb}^{-1}(x_b - \mu_b)$$

$$\bar{\Sigma}_{a|b} = \Sigma_{aa} - \Sigma_{ab}\bar{\Sigma}_{bb}^{-1}\Sigma_{ba}$$

$$\Sigma_{a|b} = \Lambda_{aa}^{-1}$$

$$\bar{\Sigma}_{a|b}^{-1} = \Lambda_{aa} = (\Sigma_{aa} - \Sigma_{ab}\bar{\Sigma}_{bb}^{-1}\Sigma_{ba})^{-1}$$

$$\begin{aligned} (\bar{\Sigma}_{a|b}^{-1})^{-1} &= \Lambda_{aa}^{-1} = \bar{\Sigma}_{a|b} \\ &= ((\Sigma_{aa} - \Sigma_{ab}\bar{\Sigma}_{bb}^{-1}\Sigma_{ba})^{-1})^{-1} \end{aligned}$$

$$\bar{\Sigma}_{a|b} = \Sigma_{aa} - \Sigma_{ab}\bar{\Sigma}_{bb}^{-1}\Sigma_{ba}$$

# Marginalización de Gaussianas

- Bajo el mismo contexto podemos encontrar:



$$p(x_a) = \int p(x_a, x_b) dx_b$$

- Expandiendo y buscando términos relacionados con  $x_b$ :

$$p(x_a) = N(x_a | \mu_a, \Sigma_{aa})$$

EJERCICIO: Demostrar.

EJERCICIO: Simular



## Teorema de Bayes para variables Gaussianas.

- Sea  $p(x)$  la pdf marginal sobre  $x \in \mathbb{R}^M$
- Sea  $p(y|x)$  una distribución Gaussiana condicional con  $\mu_{y|x}$  dada como una función lineal en  $x$ .  $\rightarrow \bar{\mathbf{x}}_{y|x}$  independiente de  $x$ . ( $y \in \mathbb{R}^D$ )
- Las anteriores condiciones permiten generar un modelo linear Gaussiano.
- Nos interesa encontrar la marginal  $p(y)$  y la condicional  $p(x|y)$ .
- Asumiendo:
  - $p(x) = N(x|\mu, \Sigma')$
  - $p(y|x) = N(y | Ax+b, L^{-1})$

donde  $\mu, A, b$  son parámetros que modelan las medias

$\Sigma, L$  matrices de precisión.

$$\mu \in \mathbb{R}^M, b \in \mathbb{R}^D, A \in \mathbb{R}^{D \times M}, L \in \mathbb{R}^{D \times D}, \Sigma \in \mathbb{R}^{M \times M}$$

- Sea  $\mathbf{z} = [\mathbf{x}, \mathbf{y}]$ , la pdf conjunta en log se puede representar como:

$$p(\mathbf{z}) = p(\mathbf{x}, \mathbf{y}) = p(\mathbf{y}|\mathbf{x})p(\mathbf{x})$$

$$\begin{aligned}\log(p(\mathbf{z})) &= \log(p(\mathbf{y}|\mathbf{x})p(\mathbf{x})) = \log(p(\mathbf{y}|\mathbf{x})) + \log(p(\mathbf{x})) \\ &= \log\left[\frac{1}{(2\pi)^{D/2} |\mathbf{L}|^{1/2}} \exp\left[-\frac{1}{2} (\mathbf{y} - \mathbf{A}\mathbf{x} - \mathbf{b})^T \mathbf{L}^{-1} (\mathbf{y} - \mathbf{A}\mathbf{x} - \mathbf{b})\right]\right] \\ &\quad + \log\left[\frac{1}{(2\pi)^{n/2} \Delta} \exp\left[-\frac{1}{2} (\mathbf{x} - \mathbf{u})^T \Delta^{-1} (\mathbf{x} - \mathbf{u})\right]\right] \\ &= -\frac{1}{2} (\mathbf{y} - \mathbf{A}\mathbf{x} - \mathbf{b})^T \mathbf{L}^{-1} (\mathbf{y} - \mathbf{A}\mathbf{x} - \mathbf{b}) - \frac{1}{2} (\mathbf{x} - \mathbf{u})^T \Delta^{-1} (\mathbf{x} - \mathbf{u}) + \text{cte.}\end{aligned}$$

**EJERCICIO:** Determine el término cte.

$$\log(p(z)) = \log(p(y, x)) = -\frac{1}{2}(y^T - (Ax)^T - b^T) L (y - Ax - b) \\ - \frac{1}{2}(x^T - u^T) \Delta (x - u) + \text{cte.}$$

$$= -\frac{1}{2} [ \underbrace{y^T L y}_{} - \underbrace{y^T L A x}_{} - \underbrace{y^T L b}_{} - \underbrace{x^T A^T L y}_{} + \underbrace{x^T A^T L A x}_{} + \underbrace{x^T A^T L b}_{} \\ - \underbrace{b^T L y}_{} + \underbrace{b^T L A x}_{} + \underbrace{b^T L b}_{} ] \\ - \frac{1}{2} [ \underbrace{x^T \Delta x}_{} - \underbrace{x^T \Delta u}_{} - \underbrace{u^T \Delta x}_{} + \underbrace{u^T \Delta u}_{} ] + \text{cte.}$$

- Factorizamos para encontrar términos cuadráticos de la forma:

$$x^T A_{xx} x, \quad x^T A_{yy} y, \quad y^T A_{yx} x, \quad x^T A_{xy} y.$$

$$\log(p(y, x)) = -\frac{1}{2} y^T L y - \frac{1}{2} x^T (\Delta + A^T L A) x + \frac{1}{2} y^T L A x + \frac{1}{2} x^T A^T L y \\ + \text{lineales en } x, y + \text{cte}$$

Así:

$$-\frac{1}{2} \begin{bmatrix} x \\ y \end{bmatrix}^T \underbrace{\begin{bmatrix} \Delta + A^T L A & -A^T L \\ -L A & L \end{bmatrix}}_{\text{MÁTRIZ DE PRECISIÓN DISTRIBUCIÓN CONJUNTA}} \begin{bmatrix} x \\ y \end{bmatrix} = -\frac{1}{2} z^T R z;$$

MÁTRIZ DE PRECISIÓN DISTRIBUCIÓN  
CONJUNTA

**EJERCICIO:** Utilizando el teorema de la matriz inversa, demostrar que:

$$R^{-1} = \begin{bmatrix} I + A^T L A & -A^T L \\ -L A & L \end{bmatrix}^{-1} = \begin{bmatrix} I' & I' A^T \\ A I' & C' + A I' A^T \end{bmatrix}^{-1} = \begin{bmatrix} \Sigma_{xx} & \Sigma_{xy} \\ \Sigma_{yx} & \Sigma_{yy} \end{bmatrix}$$

- Ahora, agrupando los términos lineales en  $\log(p(z))$ :

$$\log(p(z)) = \frac{z}{2} Y^T L b - \frac{z}{2} X^T A^T L b + \frac{z}{2} X^T S u + \text{términos cuadráticos} + \text{cte.}$$

$$= X^T (S u - A^T L b) + Y^T L b + \text{términos cuadráticos} + \text{cte.}$$

$$\begin{bmatrix} X \\ Y \end{bmatrix}^T \begin{bmatrix} S u - A^T L b \\ L b \end{bmatrix}$$

**NOTA:** Recuerda que  $-\frac{1}{2}(z - u_z)^T \bar{\Sigma}_z^{-1} (z - u_z) = -\frac{1}{2} z^T \bar{\Sigma}_z^{-1} z + z^T \bar{\Sigma}_z^{-1} u_z + \text{cte.}$

Entonces:  $z^T \bar{\Sigma}_z^{-1} u_z = \begin{bmatrix} X \\ Y \end{bmatrix}^T \begin{bmatrix} S u - A^T L b \\ L b \end{bmatrix}$

$$\bar{\Sigma}_z^{-1} u_z = \begin{bmatrix} S u - A^T L b \\ L b \end{bmatrix}$$

- Reescribiendo desde la matriz de precisión: ( $R = \Sigma_z^{-1}$ ;  $\bar{R}^i = \bar{\Sigma}_z$ )

$$-\frac{1}{2}(z - \mu_z)^T R(z - \mu_z) = -\frac{1}{2} z^T R z + z^T R \mu_z + \text{cte.}$$

$$z^T R \mu_z = \begin{bmatrix} x \\ y \end{bmatrix}^T \begin{bmatrix} \Delta u - A^T L b \\ L b \end{bmatrix}; \Sigma_z = R^{-1} = \begin{bmatrix} \bar{\Lambda}' & \bar{\Lambda}' A^T \\ A \bar{\Lambda}' & L' + A \bar{\Lambda}' A^T \end{bmatrix} = \begin{bmatrix} \bar{\Sigma}_{xx} & \bar{\Sigma}_{xy} \\ \bar{\Sigma}_{yx} & \bar{\Sigma}_{yy} \end{bmatrix}$$

$$R \mu_z = \begin{bmatrix} \Delta u - A^T L b \\ L b \end{bmatrix} \rightarrow \mu_z = \bar{R}^{-1} \begin{bmatrix} \Delta u - A^T L b \\ L b \end{bmatrix}$$

$$\mu_z = \begin{bmatrix} \bar{\Lambda}' & \bar{\Lambda}' A^T \\ A \bar{\Lambda}' & L' + A \bar{\Lambda}' A^T \end{bmatrix} \begin{bmatrix} \Delta u - A^T L b \\ L b \end{bmatrix} = \begin{bmatrix} \bar{\Lambda}'(\Delta u - A^T L b) + \bar{\Lambda}' A^T L b \\ A \bar{\Lambda}'(\Delta u - A^T L b) + (L' + A \bar{\Lambda}' A^T)L b \end{bmatrix}$$

$$\mu_z = \begin{bmatrix} u - \bar{\Lambda}' A^T L b + \bar{\Lambda}' A^T L b \\ A \bar{\Lambda}' \Delta u - A \bar{\Lambda}' A^T L b + L' L b + A \bar{\Lambda}' A^T L b \end{bmatrix} = \begin{bmatrix} u \\ b + A u \end{bmatrix} = \begin{bmatrix} \mu_x \\ \mu_y \end{bmatrix}$$

$$\boxed{\begin{bmatrix} \mu_x \\ \mu_y \end{bmatrix} = \begin{bmatrix} u \\ b + A u \end{bmatrix}};$$

$$\begin{aligned} p(x) &= N(x | u, \bar{\Lambda}') \\ p(y|x) &= N(y | Ax + b, \bar{\Sigma}') \\ p(y) &= N(y | \mu_y, \bar{\Sigma}_{yy}) = N(y | b + Au, L' + A \bar{\Lambda}' A^T) \end{aligned}$$

**NOTA:** Si  $A = I \rightarrow$  La marginal  $p(y)$  se puede escribir como la convolución de dos Gaussianas:

$$p(y) = \int p(y|x)dx = \int p(y|x)p(x)dx = \int N(y|x+b, \Sigma)N(x|u, \Sigma')dx$$

$$p(y) = N(y|u+b, \Sigma + \Sigma')$$

Ahora, para  $p(x|y)$ , recordemos que para  $p(x_a, x_b)$ :

$$p(x_a|x_b) = N(x_a|m_{ab}, \Sigma_{ab})$$

$$m_{ab} = m_a + \Sigma_{ab}\Sigma_{bb}^{-1}(x_b - m_b); \quad m_{bab} = m_a - \Lambda_{aa}^{-1}\Lambda_{ab}(x_b - m_b)$$

$$\Sigma_{ab} = \Sigma_{aa} - \Sigma_{ab}\Sigma_{bb}^{-1}\Sigma_{ba}; \quad \Sigma_{bab} = \Lambda_{aa}; \quad \Sigma_{bab} = \Lambda_{aa}^{-1}$$

Entonces, a partir de la matriz de precisión  $\Sigma$  y  $m$ :

$$R = \begin{bmatrix} \Lambda + A^T \Lambda A & -A^T \Lambda \\ -\Lambda A & \Lambda \end{bmatrix} = \begin{bmatrix} \Lambda_{xx} & \Lambda_{xy} \\ \Lambda_{yx} & \Lambda_{yy} \end{bmatrix}, \quad m = \begin{bmatrix} m_x \\ m_y \end{bmatrix} = \begin{bmatrix} u \\ b + Au \end{bmatrix}$$

$$\Sigma_{xy} = \Lambda_{xx}^{-1} = (\Lambda + A^T \Lambda A)^{-1}$$

$$m_{xy} = m_x - \Lambda_{xx}^{-1}\Lambda_{xy}(y - m_y) = u + (\Lambda + A^T \Lambda A)^{-1}A^T \Lambda (y - Au - b)$$

$$\Sigma_{x_1y} = (\lambda + A^T L A)^{-1}$$

$$\mu_{x_1y} = \mu + (\lambda + A^T L A)^{-1} (A^T L b - A^T L A \mu)$$

$$= (\lambda + A^T L A)^{-1} (\lambda + A^T L A) \mu + (\lambda + A^T L A)^{-1} (A^T L (y - b) - A^T L A \mu)$$

$$= (\lambda + A^T L A)^{-1} [A^T L (y - b) - \underline{A^T L A \mu} + \lambda \mu + \underline{\lambda \mu}]$$

$$\mu_{x_1y} = (\lambda + A^T L A)^{-1} [A^T L (y - b) + \lambda \mu]$$

$$p(x_1|y) = N(x_1 | \mu_{x_1y}, \Sigma_{x_1y})$$

EJERCICIO: Sea  $t_n = w^T \phi(x_n) + \eta$  ;

con  $w \sim p(w) = N(w | m_0, S_0)$   $\rightarrow \eta \sim p(\eta) = N(\eta | 0, B^{-1})$

Demuestre que  $p(w | t) = N(w | m_N, S_N)$

$$m_N = S_0^{-1} m_0 + \beta \phi^T t$$

$$S_N^{-1} = S_0^{-1} + \beta \phi \phi^T$$

$$\phi = [\phi(x_1), \phi(x_2), \dots, \phi(x_n)]^T \in \mathbb{R}^{Q \times N}, \quad t = [t_1, t_2, \dots, t_N]^T \in \mathbb{R}^N$$
$$w \in \mathbb{R}^Q \quad \beta \in \mathbb{R}^+$$

Demuestre que la predictiva toma la forma:

$$p(t^* | t, \phi, w) = \int p(t^* | w) p(w | t) dw$$

$$p(t^* | t, \phi, w) = N(t^* | m_N^T \phi(x^*), \sigma_N^2(x^*))$$

$$\sigma_N^2(x^*) = \frac{1}{\beta} + \phi(x^*)^T S_N \phi(x^*)$$